

选择性再掩码控制器审计与修正

为什么修改

上一版结构化控制器把 step sweep 曲线作为任务步数先验，用于估计不同任务追加预算的边际收益。这个设计可以解释实验现象，但不适合放在主方法里：如果先验来自同一批下游任务的事后扫描，它会让方法看起来依赖任务级验证信息。

因此主方法改回只使用当前样本可在线获得的信号：

1. 前向标签探针的置信度、熵和 top-2 margin。
2. 低预算侦察轨迹中的标签合法性、预测翻转和首次稳定步数。
3. 生成 token 的填充置信度。
4. 预测标签与探针标签的分歧。

step sweep 曲线只用于分析不同任务的预算敏感性，不作为默认控制器输入。

稳健主线

当前稳健主线是 8-step scout + risk-gated refinement：

1. 先执行 8 步低预算反向扩散，得到初始答案和轨迹统计。
2. 根据样本风险决定接受、追加到 16/24，或回退到 32。
3. 追加预算时只重掩低置信位置，避免过度扰动已经稳定的答案。

该路线对应已有主实验中的校准控制器和旧阈值再修结果。它的优点是稳定、无任务先验、可解释；缺点是步长粒度仍较粗。

4-step online 实验

我们尝试了更细粒度的在线控制器：

4 -> 8 -> 12 -> 16 -> 20 -> 24 -> 28 -> 32

它每 4 步重新计算风险，并决定继续或停止。这个设计看起来更细，但小样本实验显示它不适合作为当前主方法。

方法	任务	准确率	平均调用	观察
旧阈值再修	WinoGrande	0.800	14.20	稳定
4-step online	WinoGrande	0.700	18.50	多次重掩码扰动二分类答案
旧阈值再修	CommonsenseQA	0.850	9.05	稳定
4-step online	CommonsenseQA	0.850	11.00	能停在 8，但额外 4 步侦察增加成本

主要问题在于：4 步时生成已经填满，后续继续计算必须重掩码；对 WinoGrande 这类二分类语义绑定任务，反复重掩答案附近 token 会改变原本稳定的 hitting distribution，导致正确答案被扰动。

当前结论

1. 任务步数先验不作为主方法，最多作为解释性分析。
2. 更细步长没有自动带来收益；4-step online 在 WinoGrande 上是负结果。
3. 当前稳健主线应保持 8-step scout + 风险控制。
4. 后续真正值得做的改进是“非破坏性细粒度观察”，例如在 4 步时不填满所有 token，或只读取中间 logits/标签后验而不重掩已经稳定的答案。

这条结论比强行包装 4-step 方法更可靠：采样控制的关键除了预算粒度，还包括继续去噪时是否破坏已有答案轨迹。

解码机制探索结果

我们进一步实现并测试了几类候选控制器，统一使用 `seed=23`, `limit=20` 的 WinoGrande 和 CommonsenseQA 小样本集筛选。

方法	WinoGrande 准确率	WinoGrande 调用	CommonsenseQA 准确率	CommonsenseQA 调用	结论
风险门控低 置信再掩码	0.800	14.20	0.850	9.05	当前最佳
gentle remask	0.800	14.20	0.850	8.90	与默认基本 等价
answer- consistency remask	0.800	14.20	0.850	8.90	答案保护/修 复逻辑生效， 但没有超过 gentle remask
aggressive remask	0.800	14.20	0.850	9.05	无额外收益
4-step online	0.700	18.50	0.850	11.00	细粒度带来 扰动
no-prior shape routing	0.750	20.65	0.850	16.40	成本过高
trajectory- probe cascade	0.700	12.55	0.850	11.70	verifier 无法 识别 WinoGrande 错例
conservative probe cascade	0.750	25.00	0.850	14.15	保守但不划 算
schedule ensemble	0.750	16.80	0.850	16.00	一致性信号 不足

这些结果把主方法收束到一个更清晰的设计：先用 prompt probe 发现明显样本和必须满预算的样本，再用 8 步侦察和低置信再掩码修复轨迹敏感错误。额外的 verifier、双 schedule、答案一致性保护或更细粒度在线控制在当前实验里没有超过这个组合。

answer-consistency remask 的机制更复杂：当 prompt probe 与 scout 答案一致时，保护最终答案 token 和 answer marker；当 prompt probe 强烈反对 scout 答案时，把标签和 answer marker 纳入优先修复区域。20 样本实验中该分支触发 11 次 refinement，其中 6 次为答案保护，1 次为强分歧修复。最终指标与 gentle remask 相同，说明答案一致性信息没有伤害结果，但它还没有提供额外收益。

Value-of-Refinement 后验捷径

进一步分析 1000 样本主实验中的 prompt probe 后验，我们发现高置信标签后验本身就是一个强信号。最简单的阈值版使用 `top_prob >= 0.80` 且 `margin >= 0.40`，在 WinoGrande 上覆盖 43.6% 样本，直接准确率为 0.856；在 CommonsenseQA 上覆盖 73.5% 样本，直接准确率为 0.917。把这些样本从反向扩散循环中拿出来，离线模拟可在保持 WinoGrande 0.756 的同时把平均调用降到 13.98，在 CommonsenseQA 上达到 0.820、平均调用 3.15。

为了避免方法看起来只是阈值调参，我们进一步实现了 value-of-refinement 版本。它不直接判断 `top_prob` 是否超过某个数，而是比较两个动作的期望代价：

```
direct_value = posterior_risk + lambda * 1
continue_value = residual_risk_after_refinement + lambda * expected_continuation_calls
```

其中 `posterior_risk` 由 Bayes error、归一化熵、margin deficit 和标签空间复杂度组成；`expected_continuation_calls` 只依赖标签空间大小，二分类默认 14，多选默认 9，不使用任务名。若 `direct_value <= continue_value`，控制器直接提交 `posterior` 标签；否则进入 8-step scout 和后续再修。

真实 100 样本验证也支持这个方向：

方法	任务	准确率	平均调用	路由分布
probe-direct + risk-gated remask	WinoGrande	0.740	10.87	0-step: 38%, 8: 21%, 16: 24%, 24: 12%, 32: 5%
probe-direct + risk-gated remask	CommonsenseQA	0.800	5.23	0-step: 67%, 8: 9%, 16: 20%, 24: 2%, 32: 2%
value-of- refinement controller	WinoGrande	0.740	9.43	0-step: 54%, 8: 6%, 16: 24%, 24: 11%, 32: 5%
value-of- refinement controller	CommonsenseQA	0.800	5.30	0-step: 66%, 8: 10%, 16: 20%, 24: 2%, 32: 2%

这里的 0-step 表示只使用一次 masked final-label posterior probe，不进入反向扩散循环。该机制没有使用任务级先验，也没有依赖事后 step sweep；它只依据当前样本的标签后验风险和继续计算价值。与 gentle risk-gated remask 相比，value-of-refinement controller 在 WinoGrande 上准确率保持 0.740，平均调用从 13.91 降到 9.43；在 CommonsenseQA 上准确率保持 0.800，平均调用从 9.92 降到 5.30。因此最终推荐的解码机制是 value-of-refinement posterior shortcut + 8-step scout + risk-gated low-confidence remask。

100 样本再修验证

在筛掉明显负优化的候选后，我们对 gentle risk-gated remask 做了更大一轮验证，设置为 `seed=23`，`limit=100`，仍然不使用任务步数先验。

方法	任务	准确率	平均调用	路由分布
gentle risk-gated remask	WinoGrande	0.740	13.91	8: 59%, 16: 24%, 24: 12%, 32: 5%
gentle risk-gated remask	CommonsenseQA	0.800	9.92	8: 76%, 16: 20%, 24: 2%, 32: 2%

这轮结果确认了两点。第一，控制器没有退化成固定 8 步或固定 32 步，在 8/16/24/32 之间形成了非退化的样本级预算分配。第二，更复杂的 trajectory-probe cascade、schedule ensemble 和 4-step online 没有超过这个简单但稳定的风险门控机制。加入 probe-direct 捷径后，主方法进一步变成三段式：高置信标签后验直接提交，中等风险样本进入 8-step scout，高风险样本追加低置信再掩码或回退满预算。